

表 6.3 启发式选择条件消融与反例分析 (R9F)

测试用例 / 核心数	原方案 M_2 / cycles	候选方案 M_2 / cycles	原方案 M_3 / cycles	候选方案 M_3 / cycles
case_064 / 5 Core	7,029	6,899	6,981	6,877
case_068 / 5 Core	131,631	98,913	116,345	97,971
case_088 / 5 Core	97,305	66,729	85,789	66,224

这一消融实验清楚地证明：在多目标多场景评估中，人为构造的复合比值指标容易产生与核心目标背离的掩盖效应，反而排除了在官方模拟中能够大幅缩短执行时间的优秀方案。本文主算法 Forest 坚持以官方规定的主口径 Makespan 严格单调下降作为唯一的接受准则，确保了优化方向始终紧密对准赛题的首要目标。

6.5 本章小结

本章针对共享只读 Cache 与 FIFO 逐出语义，建立非交错树状模型，严格按子树存储峰值与保留输出之差的降序安排执行次序，辅以关键路径下界剪枝与在线仿真选优。在 5 核心场景下平均加速比达到 4.7576；同一方案开关 Cache 配对仿真的平均成对增益为 1.0829，平均字节命中率 31.36%。排序结论严格受限于非交错树结构，且缓存命中并不保证整体完成时间缩短（如已测旧固定方案反例增加 143 周期）。

7 综合实验与结果分析

7.1 实验设置

本文算法在官方赛题指定的全部 100 张原始计算图上展开系统性实验，计算核心数量依次配置为 1 至 5 核心，每道题目涵盖 500 种“计算图—核心数”测试组合，三道题目合计完成 1500 组完整的端到端求解与仿真评测。针对每一道题目，实验均采用运行前已完全冻结的单一固定求解器程序版本，其内部策略选择规则、候选生成数量以及在线评测调用上限在运行前全部固化，不针对特定算题进行人工微调。

实验数据由统一的数据资产库（`paper/manuscript-v1/data/all-results.csv` 与 `source-receipt.json`）导出并复核。全文分析依托于三类明确的对比维度：

- 相对官方单核心基准的加速比：**以官方提供的单核心基准方案完成时间除以算法输出方案的完成时间，严格计算每一测试用例的加速比，并计算算术平均值；
- 算法版本演进的宏观对比：**比较同一计算图和同一核心数下，不同完整算法版本之间的整体性能演进。由于每个主版本通常包含结构识别、核心放置与顺序调整等多项改进，宏观版本对比用于展示系统综合能力的提升，不将整体增益简单归因于单一机制的孤立贡献；
- 共享只读 Cache 的成对隔离对比：**针对问题三生成的同一份最终调度方案，保持任务切分与排程完全不变，分别在关闭 Cache（无 L2）与开启 Cache 两种官方硬件配置下运行离散事件仿真，严格度量共享 Cache 对同一物理调度方案执行时钟周期的纯收益。

在实验数据整理、统计口径核对与结果分析过程中，本研究采用了人工智能工具提供辅助支持。所使用的工具为 GPT-6 Astra（API 型号：gpt-6-astra，由 OpenAI 开发，版本发布日期为 2026 年 9 月 3 日）[20]。文中全部测试用例的实测数值均严格源自前述已冻

结的数据资产库与官方离散事件仿真记录，AI 输出仅用于辅助数据整理、统计指标核对与分析讨论，不作为生成新测试数值或替代离散事件仿真的依据。

图 7.1-1 给出了官方赛题提供的全部 100 张原始基准计算图的规模与静态计算时长特征：

1. 在子图（a）中，每个数据点对应一张基准计算图。横轴为图中非 COPY 计算操作的总数量（采用对数刻度），纵轴为图中全部张量的大小总和（以 MiB 为单位，采用对数刻度）；
2. 在子图（b）中，对每张计算图分别汇总矩阵类（PIPE_M）与向量类（PIPE_V）计算操作在题面模型中的标称计算周期数，纵坐标为静态矩阵标称时长占矩阵与向量标称计算时长之和的比值。横轴按该比值从小到大升序排列 100 张计算图，每张图对应一个位置。需要特别强调的是，该无量纲占比描述的是计算图的静态工作量构成，不能等同于调度后的实际物理执行时间或全局 Makespan 的占比。测试所用的全部 100 张图在研发阶段均作为已知基准参与过特征分析，本文不主观臆测具体的神经网络模型名称，亦不将其虚称为完全未见的盲测集。




图 7.1-1 官方 100 张原始计算图的规模与操作标称时长构成。（a）计算图操作数量与张量大小分布；（b）矩阵类操作标称计算时长占矩阵与向量标称计算时长之和的比例分布。

7.2 求解质量与计算效率

7.2.1 多核加速比比较

下表汇总了问题一（P1）、问题二（P2）与问题三（P3）的主算法输出方案，在 1 至 5 核心下的平均加速比。表中每格数值均基于该核心数下的 100 张基准计算图逐用例计算 B/M 后取算术平均，三道题目统一采用官方提供的单核心基准完成时间 B 作为基准分子：

表 7.1 三个问题的多核加速比综合对比

计算核心数量	P1 优化方案	P2 优化方案	P3 优化方案（开启 Cache）	P3 同方案（无 L2 运行）
1	1.0021	1.2061	1.1998	1.1971
2	1.9516	2.3167	2.3120	2.2949
3	2.7514	3.2356	3.2587	3.1745
4	3.4786	3.9711	4.0915	3.9211
5	4.0553	4.5498	4.7576	4.4763

表中所列加速比为各题目在各自硬件配置与专用求解器下的评测结果：

1. 硬件执行语义的演变：

- 问题一要求各个硬件执行任务（Task）之间传递的数据必须经由外部主存（DDR）中转，跨 Task 数据搬运产生较大的 DDR 访存开销，同时同核相邻任务切换伴随 100 cycles 上下文开销、跨核依赖伴随 1000 cycles 同步等待；
- 问题二与问题三引入同核心任务合并机制，被分配到同一核心的算子可直接在片上私有缓存（L1 Buffer 与 UB）中复用数据，取消了同一核心内部跨子图数据的强制 DDR 中转；但若存在跨核心数据流动或因局部片上容量不足触发换出换入（spill），相关数据仍需通过 DDR 搬运；
- 问题三进一步引入 1 MiB 的共享只读 Cache。依据第 6 章所述的缓存资格与 FIFO 规则，符合条件的 COPY_IN 操作若发生缓存命中，可直接从 Cache 读取数据，从而减少相应的 DDR 访存读取开销；

2. 指标统计口径的严谨区分：

- 表中第 4 列“P3 优化方案”与第 5 列“P3 同方案无 L2”由同一份 P3 调度方案在不同硬件仿真模式下评测得出；而第 3 列“P2 优化方案”是由问题二专用求解器独立优化生成的不同调度方案；
- 在 5 核心场景下，P3 方案在开启 Cache 与关闭 Cache 时的平均加速比分别为 4.7576 与 4.4763，两列平均值直接相除的比值为 $\frac{4.7576}{4.4763} \approx 1.0628$ ；而依据第 2 章定义，逐用例计算两者的成对加速比 M_2/M_3 后的算术平均值为 1.0829。产生差异的原因在于各用例的完成时间基数分布不均，本文以逐用例成对计算的算术平均值作为衡量 Cache 收益的主口径；
- 在单核心场景下，P2 与 P3 算法输出方案的 Makespan 相比官方单核基准分别取得了 1.2061 与 1.1998 的 B/M 比值，反映算法在单核排程下求得的执行周期短于官方基线，此处仅客观记录比值结果，不单独作为指令流水线重叠密度提升的微架构因果归因。

7.2.2 求解耗时与评测开销

算法的端到端求解耗时包含原始计算图解析、拓扑分析与候选构造、必要下界计算、在线代理与官方评测推进，以及最终合法方案的磁盘写入。

为了客观呈现求解效率，下表将三道题目的统计范围统一为全量 500 种测试组合（涵盖 100 张图、1 至 5 核心）。95% 分位数（P95）统一严格采用最近秩次法（nearest-rank，取排序后第 $\lceil 0.95n \rceil$ 个观测值，样本量 $n = 500$ 时对应第 475 位）：

表 7.2 算法求解耗时与评测调用次数统计

求解器与 题目范围	在线评测总调 用账本	求解耗时均值 / s	P95 耗时 / s	最大耗时 / s	运行主机 与并发环 境
P1 求解器 (全量 500 组合)	1130 次 E1 评 测 (48 次 E0 复核 + 452 次 核同复用)	2.825	13.164	25.552	共享多核 主机，4 个 并发进程
P2 求解器 (全量 500 组合)	1131 次原生 E2 评测 (0 次 E0 回退)	4.029	18.841	40.187	共享多核 主机，1 个 独占进程
P3 Forest (全量 500 组合)	973 次原生 E0 评测 (0 次异 常重试)	4.401	20.009	51.335	共享多核 主机，4 个 并发进程

针对问题一在 5 核心场景（100 个样本，对应第 95 位）下的独立统计，其求解耗时均值为 3.522 秒，P95 为 16.623 秒，最大耗时为 25.552 秒。

如表中数据所示：

1. **调用频次分布**：在三道题目各 500 种测试组合的求解过程中，在线评测调用次数平均每用例发起约 2 次（均严格在设定的上限以内，P1 至多 10 次，P2 与 P3 至多 3 次）。该频次客观记录了各算法在候选生成与前置筛选后实际发起的评测规模，不将调用次数受控直接作为各项具体守卫或剪枝机制各自有效性的孤立因果证明；
2. **端到端求解时间**：在所有 1500 次运行中（全量求解耗时分布累积曲线如图 7.2-1 所示），实际端到端求解物理耗时的最大值为 51.335 秒。赛题第 5 页脚注 1 提出的 5~10 分钟属于避免暴力迭代搜索的工程效率建议，并非程序最低运行时间要求或硬性淘汰阈值，亦非独占硬件下的性能判定。由于测试运行于共享主机且各题工作进程数不同，所记录的耗时反映工程实际测得的求解时间，不作为独占硬件条件下的算力性能基准。

7.3 方法比较与局限性

7.3.1 算法版本比较与消融

为了检验各项机制的实际影响并核实设计假设，实验区分宏观版本演进对比与受控消融/反例检验两类不同证据。在多处理器系统性能分析中，单纯统计局部算子耗时并不直接对应全局完成时间的因果改善 [21]；若多个机制同时演变，不能将整版本的宏观收益直接归因于单一孤立机制：

1. **问题一版本演进对比**：在问题一中，包含分支重排与前沿细化的新版本相比前序基准，在 5 核心场景下的平均加速比提升约 0.729%，全图额外 DDR 搬运总量微增约 0.389%。这一数据客观呈现了完整版本在提升平均加速比的同时伴随额外搬运量小幅增加的数




图 7.2-1 三种求解程序的实际经过时间累计分布，每题 500 次。时间包含方案构造及在线评价，横轴采用对数刻度；批次资源不同，不据此比较独占机器的速度。

值变动；由于该版本同时包含结构细化与拓扑次序探索等多项复合改动，此处仅记录整版本对比表现，不作单一机制的因果分摊；

2. **问题二版本演进对比：**与前一完整版本相比，P2 求解器在全量 500 个测试组合中有 268 个用例缩短了 Makespan，232 个用例持平，零退化。与此同时，500 个测试组合的额外 DDR 搬运总量增加了 36.66%。该分布客观记录了版本迭代中执行时间缩短与额外搬运量增加相伴随的成对数值变动，反映了整体方案以 Makespan 优先的选优结果，不将其作为单一超图割或工作量保护机制的独立因果归因；
3. **C04 对照策略的限定反例：**针对前期研发策略 C04 在 6 个预选 5 核心用例上的对比显示，C04 方案虽然经官方 Step 2 编译确认未发生任何片上缓存换入换出（spill 为 0），且跨核心边界搬运字节数低于主算法，但其最终 Makespan 在这 6 个用例上全部变慢（在 case_019 上变慢 75.50%）。该限定反例否定了“边界搬运更少且无换出换入则完成时间必然缩短”的假设，表明单纯优化静态搬运量并不能保证执行时间下降；
4. **问题三 Forest 方案收益统计：**与前序基线方案相比，P3 Forest 求解器在全量 500 个测试组合中，在 24 个用例上缩短了 Makespan，其余 476 个用例持平，零退化；在全网格额外 DDR 搬运量与溢出搬运量上，各有 18 个用例减少，479 个用例持平，3 个用例增加，两项统计总量各净减少 413,450,240 字节。此处记录用例计数与总量变化，不外推为全用例普适改善；
5. **R9F 复合比值准则的消融对比：**在 5 核心下对候选方案附加 $G_{\text{new}} \geq G_{\text{old}}$ （即 M_2/M_3 不下降）等三重准则的 R9F 对照实验中，有 3 个候选用例（case_064、case_068、case_088）在实际执行中无 Cache 耗时 M_2 与开启 Cache 耗时 M_3 均下降，但因无 Cache 耗时的相对降幅更大导致比值数值下降，从而被复合比值准则拒绝。该消融对比表明，在多场景多目标评估中，人为构造的复合比值指标可能对主优化目标的选优产生干扰。

7.3.2 完成时间下界与最优性差距

为了评估算法输出方案与理论极限的接近程度，实验利用静态调度全局下界分析器对问题二各核心数下的方案质量进行了数学评估。

对于任意输入计算图 G 与核心数 K ，设 L 为在固定问题二硬件配置下、对解空间 $\mathcal{F}_2(G, K)$ 中所有合法算子划分、核心分配与执行全序均成立的全局物理完成时间下界（源自历史固定的全局下界证书，由流水线不可分割计算工作量、保留计算依赖路径及关键路径工作量窗口约束综合推导得出）。定义理论最优完成时间为 $\text{OPT} = \min_{P \in \mathcal{F}_2(G, K)} M_2(P)$ ，设当前算法求得的实际合法方案完成时间为 $U = M_2(P)$ 。

由于全局下界 L 适用于全体合法解，任意合法执行的物理完成时间必然满足 $L \leq \text{OPT} \leq U$ 。因此，在 $L > 0$ 时，相对偏差比值 $\frac{U}{L} - 1$ 给出了算法当前方案与理论最优解之间相对误差的**保守数学上限**。需要明确的是，此处全局下界 L 针对于全体可行方案空间，区别于第 6 章中仅对特定已排定候选方案成立的条件时序下界 $L(P)$ ，亦不使用补充材料（见附录 C）中针对局部区间推导的残余等待公式。

依据冻结的 P2 全局理论下界评测证书记录（固定来源见附录 C，完整哈希见补充材料 `source-details.md`）：

1. **高精度达标分布**：在 1 至 5 核心下，分别有 81、62、32、33 与 23 张基准计算图严格满足 $U \leq 1.05L$ 。即在当前声明的硬件条件下，这些测试用例输出方案的 Makespan 与理论最优解的相对误差不超过 5%；
2. **多核松弛间隙演变**：在 5 核心场景下，全量计算图的平均下界加速比 $\text{mean}(B/L)$ 约为 6.108，高于算法实际达到的平均加速比 4.550。这一差距反映出静态全局下界模型松弛了片上存储容量竞争、总线读写仲裁以及跨核心复杂通信等动态瓶颈，因此 6.108 属于松弛数学边界，并不代表在真实硬件约束下已证实可达的加速比。

图 7.3-1 展示了全量 500 个评测坐标（100 张图在 1 至 5 核心下）上的平均加速比及其理论界限。图中纵轴为无量纲的平均加速比。对于每张计算图，以官方单核基准完成时间 B 为分子，由 $B > 0$ 且 $L \leq \text{OPT} \leq U$ 必然导出 $B/U \leq B/\text{OPT} \leq B/L$ 。图中两条实线与虚线分别给出了 100 张图的可行方案平均加速比 $\text{mean}(B/U)$ 与全局下界平均加速比 $\text{mean}(B/L)$ 。两线之间的阴影区域仅代表当前算法方案与松弛理论下界之间的数学间隙，并不代表这部分加速比在真实物理硬件上可以实现或预计能够获得。

图 7.3-2 进一步呈现了问题二全部 500 个测试组合相对全局必要计算下界间隙 $U/L - 1$ 的经验累积分布（ECDF），与图 7.3-1 的均值演进趋势形成互补：

- 全量 500 个测试组合的 U 精确对应当前问题二主算法（c66559a）输出方案的官方仿真完成时间，全局下界 L 来自仅考虑不可分割计算负载与必要依赖的理论推导；
- 图中 5% 虚线标明了 $U/L - 1 \leq 0.05$ 的参考门槛，在 1 至 5 核心下分别有 81、62、32、33 与 23 个用例落入该范围内；
- 需要再次强调的是，相对间隙 $U/L - 1$ 是算法方案偏离未知理论最优解的保守数学上限，并非实测误差或已证实的改进空间； $L < U$ 绝不证明该方案非最优，而主要源于全局下界忽略了片上存储竞争、总线争用及同步时延等物理约束。

7.3.3 实验结论的适用范围

本文实验结果受如下客观条件与研究范围的制约：

1. **样本关联性与统计范围**：测试所用的全部 100 张官方计算图在前期研发中均作为基准参与过特征分析。由于同一张计算图在 1 至 5 核心下的拓扑结构完全一致，不同核心数下的测试结果存在高度的内在关联性，不可将其视为 500 个独立同分布的统计样本进行假设检验，全篇 1500 种测试组合亦非统计独立样本；




图 7.3-1 同一输入、配置与合法解空间下的平均加速比及理论界对比。展示当前可行方案平均加速比 $\text{mean}(B/U)$ 与全局下界平均加速比 $\text{mean}(B/L)$ 随核心数演进的数学界限（阴影区域表示松弛理论间隙，非可实现加速比）。




图 7.3-2 问题二全局理论下界间隙累积分布。展示 1 至 5 核心场景下（每组 100 用例）相对下界间隙 $U/L - 1$ 的经验累积分布（ECDF），虚线标明 5% 误差门槛；该间隙为未知真实最优性误差的保守上界，而非实测误差或预计可达收益。

2. **结构自适应与通用性**：算法内部的分支选择依据图的无向连通分量数量、算子出度以及流水线工作量等拓扑结构特征自动决策，避免了按用例编号显式查表，但其在完全未见的外部工业模型计算图上的表现仍有待进一步实测验证；
3. **仿真模型与物理硬件差异**：方案的最终质量指标（Makespan 与额外数据搬运量）完全由官方离散事件仿真器（`schedule_step2.py` 与 `schedule_step3.py`）推进时钟得出，端到端求解耗时由通用计算机的墙钟秒数记录。官方离散事件仿真模型提供了统一可比的基准评测环境，但本研究尚未在真实的神经网络处理器（NPU）物理芯片上部署运行并开展板级实测，仿真时钟周期不直接等价于已在真机上验证的物理性能收益。

8 模型评价与总结

8.1 方法特点

针对通用神经网络处理器的多核心调度需求，本文针对赛题三问不同的芯片存储与执行规则，协同优化算子划分、核心分配与执行顺序三个决策维度：

1. **问题一（子图独立封装）**：识别无数据依赖的计算分支并在核心间重新分配，均衡各核心计算流水线的工作量，结合拓扑前沿细化权衡并行收益与 DDR 通信开销；
2. **问题二（同核子图合并）**：构建超图连接度模型刻画多算子张量复用，推导换入换出前的原始复制字节数，并在二核心局部调整中通过流水线工作量上限保护机制防止算力向单核过度倾斜；
3. **问题三（引入共享只读缓存）**：针对满足接受条件的归约森林结构，依据各子树内部峰值与保留输出的差值降序排定非交错执行顺序，并在候选方案上构建基于硬件流水线必要不等式的时间下界以过滤低效搜索。

各章节的数学分析针对明确的物理与图论问题提供依据：通过标号偏序证明扩展依赖图不存在循环死锁；通过超边连接度模型解释同时移动多个消费算子与边界复制量的非线性阶跃关系；通过相邻子树对调证明在非交错执行模型下使内部结果存储峰值最小的排序准则；通过底层必要不等式建立完成时间下界以快速剪除缺乏潜力的候选方案。这些理论性质均受限于所设定的结构模型，不替代底层的离散事件评测。

8.2 主要结果

本文实现的三个固定求解器版本，在官方指定的全部 100 张基准计算图、涵盖 1 至 5 核心的 1500 种测试组合上完成了全部评测，所有方案均顺利通过官方合法性校验：

1. **多核加速比表现**：在 5 核心配置下，问题一、二、三在 100 张基准图上相对官方单核基准的平均加速比分别达到 4.0553、4.5498 与 4.7576；
2. **共享缓存成对增益**：在问题三 5 核心 100 张计算图的测试中，保持方案完全不变的前提下，开启共享只读 Cache 相比关闭 Cache 的成对平均加速比为 1.0829，平均字节命中率为 31.36%；
3. **求解效率表现**：在共享多核主机环境下，三道题目各 500 种测试组合的单用例端到端求解耗时均值分别为 P1 2.825 秒、P2 4.029 秒与 P3 4.401 秒，单用例最大求解耗时分别为 25.552 秒、40.187 秒与 51.341 秒，均显著优于原题建议的 5~10 分钟运行区间。

需要明确区分的是，方案完成时间由官方评测程序推进的离散事件仿真时钟周期（cycles）度量，求解效率由通用计算机上的实际运行墙钟时间（秒）度量；本文所呈现的数据反映在规定基准与配置下的模拟测试记录，不代表在真实物理芯片上的板级实测结果。

8.3 模型局限性

算法在实际应用中受以下条件制约：

1. **动态硬件争用与模型松弛**: 总线带宽争用、Cache 动态插入逐出以及片上存储空间分配存在复杂的时序交织。理论文献中针对有界树宽图在允许资源松弛的条件下建立了双指标完全多项式时间近似方案 (FPTAS) [22]; 然而本题涉及张量动态生命周期、硬性片上容量约束以及共享只读 Cache 的 FIFO 逐出, 无法直接继承该类近似保证;
2. **结构假设与适用范围**: 森林内存排序与下界分析依赖于特定的图结构特征。若算子存在跨分支的多重消费 (fanout), 或包含未指定张量大小的直接计算边, 则无法直接套用该排序模型;
3. **评价准则的设计权衡**: 如 C04 与 R9F 消融实验所示, 单纯优化静态通信量或人为引入复合比值门槛可能导致放弃完成时间更短的方案, 决策逻辑仍须紧密围绕主优化目标完成时间 (Makespan) 展开。

8.4 结论

实验表明, 面向多核处理器的复杂计算图调度问题, 通过图拓扑与硬件特征构造少量结构化方案, 结合理论必要条件实施剪枝保护, 并利用受限的在线评测预算进行比较择优, 能够在赛题建议的高效时间范围内获得符合官方优化目标的合法调度方案。

参考文献

- [1] 第二十三届中国研究生数学建模竞赛, A 题: 通用神经网络处理器下的多核调度问题及官方附件, 2026。
- [2] POPP M, SCHLAG S, SCHULZ C, SEEMAIER D, Multilevel Acyclic Hypergraph Partitioning, 2021 Proceedings of the Symposium on Algorithm Engineering and Experiments (ALENEX): 1–15, 2021. DOI: 10.1137/1.9781611976472.1.
- [3] 张洪滨, 周旭林, 邢明杰, 等, AutoConfig: 面向深度学习编译优化的自动配置机制, 软件学报, 35(6): 2668–2686, 2024. DOI: 10.13328/j.cnki.jos.007102.
- [4] 高伟, 李帅龙, 茆琳, 等, 一种基于 TVM 的算子生成加速策略, 计算机工程, 50(8): 353–362, 2024. DOI: 10.19678/j.issn.1000-3428.0068182.
- [5] TOPCUOGLU H, HARIRI S, WU M Y, Performance-effective and low-complexity task scheduling for heterogeneous computing, IEEE Transactions on Parallel and Distributed Systems, 13(3): 260–274, 2002. DOI: 10.1109/71.993206.
- [6] DROBOUCHEVITCH I G, STRUSEVICH V A, A heuristic algorithm for two-machine re-entrant shop scheduling, Annals of Operations Research, 86: 417–439, 1999. DOI: 10.1023/A:1018927407164.
- [7] LIU R, PEI M, DING F, et al, LATTICE: Constraint-Directed Scheduling, Memory Planning, and Pipeline Refinement for NPUs (arXiv:2607.17422v3, 2026-08-04), <https://arxiv.org/abs/2607.17422v3>, 访问时间: 2026 年 09 月 26 日。DOI: 10.48550/arXiv.2607.17422.
- [8] ÖZKAYA M Y, ÇATALYÜREK Ü V, A Simple and Elegant Mathematical Formulation for the Acyclic DAG Partitioning Problem (arXiv:2207.13638, 2022), <https://arxiv.org/abs/2207.13638>, 访问时间: 2026 年 09 月 26 日。DOI: 10.48550/arXiv.2207.13638.
- [9] MOREIRA O, POPP M, SCHULZ C, Graph Partitioning with Acyclicity Constraints (arXiv:1704.00705, 2017), <https://arxiv.org/abs/1704.00705>, 访问时间: 2026 年 09 月 27 日。DOI: 10.48550/arXiv.1704.00705.

- [10] GRAHAM R L, Bounds for Certain Multiprocessing Anomalies, Bell System Technical Journal, 45(9): 1563–1581, 1966。DOI: 10.1002/j.1538-7305.1966.tb01709.x.
- [11] BACCELLI F, COHEN G, OLSDER G J, QUADRAT J P, Synchronization and Linearity: An Algebra for Discrete Event Systems, Chichester: John Wiley & Sons, 11–13、109–110, 1992。
- [12] KAHN A B, Topological sorting of large networks, Communications of the ACM, 5(11): 558–562, 1962。DOI: 10.1145/368996.369025.
- [13] BLACK P E, Hyperedge; Hypergraph (Dictionary of Algorithms and Data Structures, NIST), <https://xlinux.nist.gov/dads/HTML/hyperedge.html>, 访问时间: 2026 年 09 月 26 日。
- [14] ÇATALYÜREK Ü V, AYKANAT C, Hypergraph-Partitioning-Based Decomposition for Parallel Sparse-Matrix Vector Multiplication, IEEE Transactions on Parallel and Distributed Systems, 10(7): 673–693, 1999。DOI: 10.1109/71.780863.
- [15] VELDT N, BENSON A R, KLEINBERG J, Hypergraph Cuts with General Splitting Functions, SIAM Review, 64(3): 650–685, 2022。DOI: 10.1137/20M1321048.
- [16] DINIC E A, An algorithm for the solution of the max-flow problem with the polynomial estimation, Soviet Mathematics Doklady, 11: 1277–1280, 1970。
- [17] EYRAUD-DUBOIS L, MARCHAL L, SINNEN O, VIVIEN F, Parallel scheduling of task trees with limited memory, Inria Research Report RR-8606, 2014。
<https://arxiv.org/abs/1410.0329>. DOI: 10.48550/arXiv.1410.0329.
- [18] SETHI R, ULLMAN J D, The Generation of Optimal Code for Arithmetic Expressions, Journal of the ACM, 17(4): 715–728, 1970。DOI: 10.1145/321607.321620.
- [19] JIN C, PUROHIT M, SVITKINA Z, VEE E, WANG J R, New Tools for Peak Memory Scheduling (arXiv:2312.13526, 2023), <https://arxiv.org/abs/2312.13526>, 访问时间: 2026 年 09 月 26 日。DOI: 10.48550/arXiv.2312.13526.
- [20] OpenAI, GPT-6 Astra (型号: gpt-6-astra) [EB/OL], 2026-09-03, <https://developers.openai.com/api/docs/models/gpt-6-astra>, 访问时间: 2026 年 09 月 27 日。
- [21] CURTSINGER C, BERGER E D, Coz: Finding Code that Counts with Causal Profiling, Proceedings of the 25th Symposium on Operating Systems Principles: 184–197, 2015。DOI: 10.1145/2815400.2815409.
- [22] ANGEL E, MORAIS S, REGNAULT D, A Bi-Criteria FPTAS for Scheduling with Memory Constraints on Graphs with Bounded Tree-Width, Euro-Par 2022: Parallel Processing. LNCS 13440: 136–151, 2022。DOI: 10.1007/978-3-031-12597-3_9.

附录 A 全量用例测试结果与数据说明

`data/all-results.csv` 保存三题共 1500 种计算图与核心数配置组合的完整测试结果。因全量表篇幅较大, 完整数据清单独立排版于附录文档 `result-tables.pdf` 中供查阅。数据表以周期 (cycle) 记录单核基线与多核完成时间, 以字节 (B) 记录额外 DDR 搬运量, 以秒 (s) 记录端到端求解耗时, 问题三另记录无 L2 对照结果与 Cache 字节命中率 (%)。正文所有聚合统计均基于未舍入的原始数据计算; 数据来源文件及其 SHA-256 校验和在 `data/source-receipt.json` 中逐项归档。